

问题的表示

- 学习问题的表示

- 给定有监督训练样本集 $D = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$, 类别标签 $y_i = j$ 表示 $\mathbf{x}_i \in \omega_j$;
- 根据类别标签可以将训练集划分为 c 个子集:

$$D = D_1 \cup D_2 \cup \dots \cup D_c$$

- 贝叶斯分类器学习的任务就是根据每个类别的训练子集 D_i , 来估计这个类别的条件概率密度 $p(\mathbf{x}|\omega_i)$;

● 概率密度的估计

- 这是一个典型的统计学中的概率密度估计问题；
- 每个类别的估计是单独完成的，为了表述方便省略类别下标，将估计问题表示为：

$$D = \{\mathbf{x}_1, \dots, \mathbf{x}_n\} \longrightarrow p(\mathbf{x})$$

- ◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ↺ 🔍 ↻

Gauss Mixture Model

- “通用”的概率密度函数

- 最大似然估计需要训练数据符合何种分布的先验知识;
- 实际应用中, 往往缺乏这样的先验知识;
- GMM可以看作是一种"通用"的概率密度函数
 - 数量 M 足够大, GMM可以任意精度逼近任意分布密度函数;

GMM的参数估计问题

- 已知数据集 D_Y 的条件下
 - 可以很容易地估计GMM的参数;
 - 定义示性函数:

$$I(t) = \begin{cases} 1, & t \text{ is true} \\ 0, & t \text{ is false} \end{cases}$$

- $\{\alpha_k\}$ 是选择成份高斯的概率，用高斯被选择的频度估计：


$$\hat{\alpha}_k = \frac{1}{n} \sum_{i=1}^n I(y_i = k)$$

- 每个高斯的参数用该高斯产生的样本估计:

$$\begin{aligned}\hat{\boldsymbol{\mu}}_k &= \frac{\sum_{i=1}^n I(y_i = k) \mathbf{x}_i}{\sum_{i=1}^n I(y_i = k)} \\ \hat{\boldsymbol{\Sigma}}_k &= \frac{\sum_{i=1}^n I(y_i = k) (\mathbf{x}_i - \hat{\boldsymbol{\mu}}_k)(\mathbf{x}_i - \hat{\boldsymbol{\mu}}_k)^t}{\sum_{i=1}^n I(y_i = k)}\end{aligned}$$

- EM算法的极值点

- 对数似然函数存在多个极值点；
- EM算法收敛于哪一个极值点，受到初始值设置的影响；
 - K-means算法的聚类结果同样受到初始设置的影响；



1阶Markov模型

- **Markov Model**

- Markov模型包含 M 个状态:


w_1, \dots, w_M

- 时刻 t , 模型处于状态 $w(t)$, 并且发生一次状态转移:

$$w(t) \rightarrow w(t+1)$$

- 经过 T 个时刻，可以得到状态转移序列：

$$W^T = w(1) \cdots w(T)$$



◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ 🔍 ↺

HMM的核心问题

● 估值问题

- 已知HMM的模型参数 θ ，计算模型输出特定观察序列 V^T 的概率 $P(V^T|\theta)$ ；
- 识别过程中，需要计算每个类别的HMM模型输出待识别序列 V^T 的类条件概率(密度)；

● 解码问题

- 已知HMM的模型参数 θ ，计算最有可能输出的特定观察序列 V^T 的隐状态转移序列 W^T ；
- 解码多用于时间序列的分割，如语音分割，动作视频分割；

● 学习问题

- 已知HMM模型的结构，根据一组训练序列学习参数 θ ；

例题3.1

计算隐状态序列与观察序列同时发生的概率：

$$\begin{aligned}
 P(V^5, W_1^5) &= \pi_1 b_{12} a_{11} b_{12} a_{11} b_{11} a_{11} b_{13} a_{11} b_{11} \\
 P(V^5, W_2^5) &= \pi_1 b_{12} a_{11} b_{12} a_{11} b_{11} a_{11} b_{13} a_{12} b_{21} \\
 P(V^5, W_3^5) &= \pi_1 b_{12} a_{11} b_{12} a_{11} b_{11} a_{11} b_{13} a_{13} b_{31} \\
 P(V^5, W_4^5) &= \pi_1 b_{12} a_{11} b_{12} a_{11} b_{11} a_{11} b_{13} a_{14} b_{41} \\
 P(V^5, W_5^5) &= \pi_1 b_{12} a_{11} b_{12} a_{11} b_{11} a_{12} b_{23} a_{21} b_{11} \\
 P(V^5, W_6^5) &= \pi_1 b_{12} a_{11} b_{12} a_{11} b_{11} a_{12} b_{23} a_{22} b_{21} \\
 P(V^5, W_7^5) &= \pi_1 b_{12} a_{11} b_{12} a_{11} b_{11} a_{12} b_{23} a_{23} b_{31} \\
 P(V^5, W_8^5) &= \pi_1 b_{12} a_{11} b_{12} a_{11} b_{11} a_{12} b_{23} a_{24} b_{41} \\
 &\dots\dots\dots
 \end{aligned}$$

HMM输出 V^5 的概率：

$$P(V^5) = \sum_{r=1}^{1024} P(V^5, W_r^5)$$

估值问题

● 简化计算

- 估值问题直接计算的复杂度高: $O(M^T T)$
- 计算过程是可以简化的;

$$P(V^5, W_1^5) = \pi_1 b_{12} a_{11} b_{12} a_{11} b_{11} a_{11} b_{13} a_{11} b_{11}$$

$$P(V^5, W_2^5) = \pi_1 b_{12} a_{11} b_{12} a_{11} b_{11} a_{11} b_{13} a_{12} b_{21}$$

$$P(V^5, W_3^5) = \pi_1 b_{12} a_{11} b_{12} a_{11} b_{11} a_{11} b_{13} a_{13} b_{31}$$

$$P(V^5, W_4^5) = \pi_1 b_{12} a_{11} b_{12} a_{11} b_{11} a_{11} b_{13} a_{14} b_{41}$$

$$P(V^5, W_5^5) = \pi_1 b_{12} a_{11} b_{12} a_{11} b_{11} a_{12} b_{23} a_{21} b_{11}$$

$$P(V^5, W_6^5) = \pi_1 b_{12} a_{11} b_{12} a_{11} b_{11} a_{12} b_{23} a_{22} b_{21}$$

$$P(V^5, W_7^5) = \pi_1 b_{12} a_{11} b_{12} a_{11} b_{11} a_{12} b_{23} a_{23} b_{31}$$

$$P(V^5, W_8^5) = \pi_1 b_{12} a_{11} b_{12} a_{11} b_{11} a_{12} b_{23} a_{24} b_{41}$$

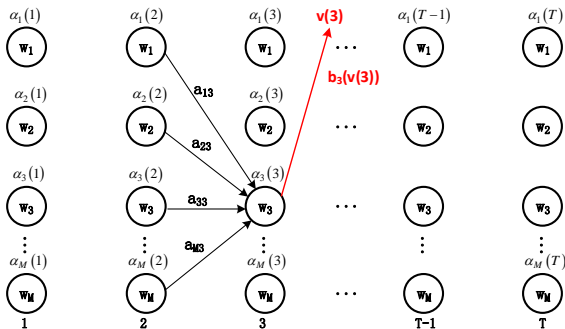
.....

估值问题

● 前向迭代

- 定义变量 $\alpha_i(t)$: 时刻 t , 模型处于隐状态 w_i , 并且输出观察序列 $V^{1 \rightarrow t} = v(1) \cdots v(t)$ 的概率

$$\alpha_i(t) = P(V^{1 \rightarrow t}, w(t) = w_i | \theta)$$



α 的迭代计算

$$\begin{aligned}
 \alpha_i(t+1) &= P(V^{1 \rightarrow t+1}, w(t+1) = w_i) \\
 &= P(V^{1 \rightarrow t}, v(t+1), w(t+1) = w_i) \\
 &= \sum_{j=1}^M P(V^{1 \rightarrow t}, v(t+1), w(t) = w_j, w(t+1) = w_i) \\
 &= \sum_{j=1}^M \left[P(v(t+1) | V^{1 \rightarrow t}, w(t) = w_j, w(t+1) = w_i) \times \right. \\
 &\quad \left. P(w(t+1) = w_i | V^{1 \rightarrow t}, w(t) = w_j) \times P(V^{1 \rightarrow t}, w(t) = w_j) \right] \\
 &= \sum_{j=1}^M \left[P(v(t+1) | w(t+1) = w_i) \times \right. \\
 &\quad \left. P(w(t+1) = w_i | w(t) = w_j) \times P(V^{1 \rightarrow t}, w(t) = w_j) \right] \\
 &= \sum_{j=1}^M \alpha_j(t) a_{ji} b_i(v(t+1)) \\
 P(V^T | \theta) &= \sum_{i=1}^M P(V^T, w(T) = w_i | \theta) = \sum_{i=1}^M \alpha_i(T)
 \end{aligned}$$

前向算法

Algorithm 4 前向算法(计算复杂度 $O(M^2T)$)

Input: HMM模型参数 θ , 观察序列 V^T

Output: 模型输出观察序列的概率 $P(V^T|\theta)$

1: 初始化: $i = 1, \dots, M$

$$\alpha_i(1) = \pi_i b_i(v(1))$$

2: 迭代递推: $i = 1, \dots, M, t = 1, \dots, T - 1$

$$\alpha_i(t+1) = \left[\sum_{j=1}^M \alpha_j(t) a_{ji} \right] b_i(v(t+1))$$

3: 结束输出:

$$P(V^T|\theta) = \sum_{i=1}^M P(V^T, w(T) = w_i|\theta) = \sum_{i=1}^M \alpha_i(T)$$

解码问题

● 解码问题

- 已知模型参数 θ ，计算最有可能输出观察序列 V^T 的状态转移序列，类似于估值问题：


$$\begin{aligned} W_*^T &= \arg \max_{W^T} P(V^T, W^T | \theta) \\ &= \arg \max_{W^T} P(V^T | W^T, \theta) P(W^T | \theta) \end{aligned}$$

- 直接计算的复杂度为 $O(M^T T)$ ；
- 存在复杂度为 $O(M^2 T)$ 的简化算法：Viterbi算法

解码问题

定义变量

- $\delta_i(t)$: 时刻 t 模型处于状态 w_i , 输出 $V^{1 \rightarrow t}$ 的最优路径概率;
- $\phi_i(t)$: 最优路径上 $t-1$ 时刻的状态, 用于路径回溯;



Viterbi算法

Algorithm 5 Viterbi算法(计算复杂度 $O(M^2T)$)

Input: HMM模型参数 θ , 观察序列 V^T

Output: 模型输出观察序列的最优隐状态序列 W^*

1: 初始化: $i = 1, \dots, M$

$$\delta_i(1) = \pi_i b_i(v(1)), \quad \phi_i(1) = 0$$

2: 迭代递推: $i = 1, \dots, M, t = 1, \dots, T - 1$

$$\delta_i(t+1) = \max_{1 \leq j \leq M} [\delta_j(t) a_{ji}] b_i(v(t+1))$$

$$\phi_i(t+1) = \arg \max_{1 \leq j \leq M} [\delta_j(t) a_{ji}]$$

3: 结束输出:

$$P^*(V^T | \theta) = \max_{1 \leq j \leq M} \delta_j(T), \quad w^*(T) = \arg \max_{1 \leq j \leq M} \delta_j(T)$$

4: 路径回溯: $w^*(t) = \phi_{w^*(t+1)}(t+1)$

HMM的拓扑结构

HMM模型的拓扑结构可以根据实际问题的需要来设计;


“左-右”模型结构:



$$\boldsymbol{\pi} = (1, 0, \dots, 0)^t, \quad A = \begin{bmatrix} a_{11} & a_{12} & \cdots & 0 \\ 0 & a_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & a_{MM} \end{bmatrix}$$

HMM的拓扑结构

帶跨越的“左-右”模型結構:



$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1M} \\ 0 & a_{22} & \cdots & a_{2M} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & a_{MM} \end{bmatrix}$$

正态分布密度参数的贝叶斯估计

样本 x 的后验分布:

$$\begin{aligned}
 p(x|D) &= \int p(x|\mu)p(\mu|D)d\mu \\
 &= \int \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right] \frac{1}{\sqrt{2\pi}\sigma_n} \exp\left[-\frac{1}{2}\left(\frac{\mu-\mu_n}{\sigma_n}\right)^2\right] d\mu \\
 &= \frac{f(\sigma, \sigma_n)}{2\pi\sigma\sigma_n} \exp\left[-\frac{1}{2}\frac{(x-\mu_n)^2}{\sigma^2 + \sigma_n^2}\right] \\
 &= N(\mu_n, \sigma^2 + \sigma_n^2)
 \end{aligned}$$

其中:

$$f(\sigma, \sigma_n) = \int \exp\left[-\frac{1}{2}\frac{\sigma^2 + \sigma_n^2}{\sigma^2\sigma_n^2}\left(\mu - \frac{\sigma_n^2 x + \sigma^2 \mu_n}{\sigma^2 + \sigma_n^2}\right)^2\right] d\mu = \frac{\sqrt{2\pi}\sigma\sigma_n}{\sqrt{\sigma^2 + \sigma_n^2}}$$

◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ↺ 🔍 ↻